RESEARCH GAP

KLASIFIKASI TIPE DAN WARNA KARTU DIGIMON CARD GAME MENGGUNAKAN CONVOLUTIONAL NEURAL NETWORK

Oleh:

Muhammad Abdul Aziz

NPM 23081010229

PROGRAM STUDI INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS PEMBANGUNAN NASIONAL "VETERAN"
JAWA TIMUR

2026

DAFTAR ISI

1. Peta Literatur **1**

1.1 Pengenalan kartu *trading card game* dan kartu permainan (paling dekat dengan topik) 1

1.2 Penelitian lokal (SINTA) klasifikasi citra dengan CNN dan *transfer learning* . 2

1.3 Landasan metodologis 2

2. Matriks Celah (Gap Matrix) **3**

3. Pernyataan Research Gap **4**

4. Posisi dan Kontribusi Penelitian **5**

5. Pertanyaan Riset ↔ Celah **5**

6. Dasar Metodologis Penelitian **5**

7. Catatan untuk Pengembangan Menjadi Paper (UAS) **5**

Daftar Pustaka **6**

Catatan metode. Peta ini disusun dari penelusuran literatur terarah (Google Scholar, arXiv, portal jurnal SINTA, repositori universitas, dan sumber industri) dan dibaca pada tingkat abstrak/ringkasan, **bukan** *systematic review*. Tanda ✗ berarti "tidak disebut pada abstrak/ringkasan yang ditinjau", sehingga perlu diverifikasi pada naskah penuh sebelum dijadikan klaim final di paper.

1. Peta Literatur

1.1 Pengenalan kartu *trading card game* dan kartu permainan (paling dekat dengan topik)

Ref	Studi	Objek	Pendekatan	Temuan	Keterbatasan terhadap topik ini
[1]	Zilio dkk. (2018), arXiv	Kartu *Magic: The Gathering*	CNN memprediksi warna dan tipe kartu dari ilustrasi dan teks	Atribut kartu dapat dipelajari dari gambar	Hanya MTG; tidak membahas varian ilustrasi, watermark, maupun kebocoran antar-varian
[2]	Nyckel (t.t.), layanan komersial	Kartu *Yu-Gi-Oh!*	Klasifikasi kategori kartu (Effect, Fusion, Link, dll.) dari foto	Model siap pakai	Metodologi, data, dan akurasi tidak dipublikasikan
[3]	Rosebrock (2021), PyImageSearch	Kartu *Yu-Gi-Oh!* (10.856 kartu)	*Triplet network* ResNet-101 + *re-ranking* ORB	Mengenali lebih dari 10.000 kartu; mayoritas kartu hanya punya satu ilustrasi	Identifikasi kartu, bukan atribut; non-akademik tanpa protokol evaluasi formal
[4]	Pua (2024), laporan proyek Stanford CS231n	Kartu *Pokémon* dari rekaman turnamen	*Fine-tuning* YOLOv8 segmentasi dengan data sintetis	mAP50-95 0,441; kartu foil (*holographic*) sering terlewat	Deteksi/segmentasi 10 kartu, bukan klasifikasi atribut
[5]	Wzorek & Kryjak (2021), arXiv	Kartu remi (bridge)	Dataset sintetis + deteksi YOLOv4	Efektivitas deteksi 99,8%	52 kelas tetap; tanpa atribut warna/tipe
[6]	Čampelj (2022), skripsi Univ. Ljubljana	Kartu Tarok	YOLO + dataset sintetis, divalidasi dengan gambar nyata	Penghitung poin otomatis	Kelas sedikit dan tetap

1.2 Penelitian lokal (SINTA) klasifikasi citra dengan CNN dan *transfer learning*

Ref	Studi	Objek	Model	Temuan	Keterbatasan terhadap topik ini
[7]	Herlawati dkk. (2026), *J. Komtika*	Daun herbal dan *undertone* kulit wajah	ResNet50 vs MobileNetV2	ResNet50 95,00% vs MobileNetV2 94,09% (daun); 89,3% vs 68,3% (kulit)	Selisih antar-arsitektur sangat bergantung domain; tanpa uji signifikansi
[8]	Rayhan dkk. (2024), *J. Cerita*	Makanan tradisional Indonesia	EfficientNetV2 vs MobileNetV2	EfficientNetV2 31% vs MobileNetV2 99%	Selisih ekstrem tanpa analisis penyebab; tanpa *cross-validation*
[9]	Hartono & Muslikh (2025), *JISAD*	20 jenis buah (4.000 citra)	MobileNetV2 *transfer learning*	Akurasi ±94%; precision, recall, F1 rata-rata 0,93–0,94	Satu arsitektur; kelas seimbang
[10]	Supriyanti & Anggoro (2021), *Khazanah Informatika*	Tokoh Pandawa pada citra wayang (430 citra, 4 kelas)	CNN dari nol (3 lapis konvolusi)	Akurasi 0,93	Dataset kecil tanpa *transfer learning*; satu kali pembagian data

1.3 Landasan metodologis

Ref	Studi	Peran dalam penelitian ini
[11], [12]	LeCun dkk. (2015); Deng dkk. (2009)	Dasar CNN dan dataset ImageNet untuk bobot *pretrained*
[13]	Yosinski dkk. (2014)	Fitur lapisan awal CNN dapat dipindahkan ke tugas lain (*transfer learning*)
[14]–[16]	He dkk. (2016); Sandler dkk. (2018); Tan & Le (2019)	Arsitektur ResNet-50, MobileNetV2, EfficientNet-B0
[17]	Selvaraju dkk. (2017)	Grad-CAM untuk interpretabilitas
[18]	Kapoor & Narayanan (2023)	Kebocoran data sebagai sumber hasil yang terlalu optimistis
[19]	He & Garcia (2009)	Pembelajaran pada data tidak seimbang dan metrik yang sesuai
[20], [21]	McNemar (1947); Dietterich (1998)	Uji McNemar untuk membandingkan dua pengklasifikasi

2. Matriks Celah (Gap Matrix)

Legenda: ✓ ada | ✗ tidak disebut pada ringkasan yang ditinjau | — tidak berlaku. **Kartu TCG:** objek berupa kartu *trading card game*; **Atribut kartu:** mengklasifikasikan atribut (tipe/warna/kategori), bukan identitas kartu; **≥ 2 arsitektur:** membandingkan minimal dua arsitektur CNN; **Varian ilustrasi:** menguji kartu bernomor sama dengan ilustrasi berbeda; **Split per grup:** pembagian data per nomor kartu/objek untuk mencegah kebocoran; **Metrik per kelas:** melaporkan *precision*/*recall*/F1 per kelas atau *macro F1*; **Uji statistik:** uji signifikansi antar-model.

Studi	Kartu TCG	Atribut kartu	*Transfer learning*	≥ 2 arsitektur	Varian ilustrasi	Split per grup	Metrik per kelas	Uji statistik	Grad-CAM
Zilio dkk. [1]	✓	✓	✗	✗	✗	✗	✗	✗	✗
Nyckel [2]	✓	✓	✗	✗	✗	✗	✗	✗	✗
Rosebrock [3]	✓	✗	✓	✗	✗	✗	✗	✗	✗
Pua [4]	✓	✗	✓	✗	✗	✗	✗	✗	✗
Wzorek & Kryjak [5]	✗	✗	✗	✗	—	✗	✗	✗	✗
Čampelj [6]	✗	✗	✗	✗	—	✗	✗	✗	✗
Herlawati dkk. [7]	✗	—	✓	✓	—	✗	✗	✗	✗
Rayhan dkk. [8]	✗	—	✓	✓	—	✗	✗	✗	✗
Hartono & Muslikh [9]	✗	—	✓	✗	—	✗	✓	✗	✗
Supriyanti & Anggoro [10]	✗	—	✗	✗	—	✗	✗	✗	✗
Penelitian ini	✓	✓	✓	✓	✓	✓	✓	✓	✓

3. Pernyataan Research Gap

Dari literatur yang berhasil ditinjau:

Kode	Celah	Bukti
G1 — Domain	Belum ditemukan penelitian ilmiah klasifikasi kartu ***Digimon Card Game***, terutama versi bahasa Jepang. Penelitian TCG yang ada berfokus pada *Magic: The Gathering*, *Yu-Gi-Oh!*, dan *Pokémon*, dan sebagian besar non-akademik. Penelitian lokal (SINTA) yang ditinjau belum menyentuh domain kartu.	Bagian 1.1 dan 1.2
G2 — Varian ilustrasi	Ketahanan model terhadap **ilustrasi *parallel*** (nomor kartu sama, ilustrasi berbeda) belum dievaluasi. Belum diketahui apakah model mengenali atribut dari desain kartu atau menghafal ilustrasinya.	Matriks celah, kolom "Varian ilustrasi"
G3 — Protokol evaluasi	Belum ditemukan studi kartu yang memakai **pembagian data berbasis grup** untuk mencegah kebocoran antar-varian, disertai **macro F1** untuk kelas tidak seimbang dan **uji signifikansi** antar-model. Studi lokal [7], [8] menunjukkan selisih antar-arsitektur yang sangat berbeda antar-domain tanpa uji statistik.	Matriks celah; [7], [8], [18]
G4 — Data riil berwatermark	Pengaruh elemen non-kartu (watermark toko dan overlay "SAMPLE") pada keputusan CNN belum dianalisis. Penelitian kartu sebelumnya memakai gambar resmi atau data sintetis.	Bagian 1.1; kolom "Grad-CAM"
G5 — Aturan label kartu dua warna	Belum ada aturan label kartu dua warna beserta dampaknya pada desain augmentasi: *horizontal flip* dan perubahan *hue* yang umum dipakai justru membuat label salah.	Bagian 1.1 dan 1.2

4. Posisi dan Kontribusi Penelitian

1. **Empiris:** studi klasifikasi tipe dan warna pertama untuk *Digimon Card Game* (dalam literatur yang ditinjau), membandingkan CNN dari awal dengan tiga model *transfer learning*.
2. **Metodologis:** protokol evaluasi bebas kebocoran (*stratified group 5-fold* per nomor kartu), skenario ketahanan terhadap ilustrasi *parallel* dan set baru, macro F1, dan uji McNemar.
3. **Interpretabilitas:** analisis Grad-CAM untuk memeriksa apakah model melihat bar nama dan tata letak kartu, bukan ilustrasi atau watermark.
4. **Sumber daya:** dataset 697 gambar berlabel tipe dan warna, beserta skrip pembangun metadata dan *pipeline* yang dapat direproduksi.
5. **Lokal:** menambah rujukan berbahasa Indonesia untuk klasifikasi citra pada domain hobi/koleksi.

5. Pertanyaan Riset ↔ Celah

Rumusan masalah	Celah yang dijawab
RM1: performa CNN untuk tipe dan warna	G1, G3
RM2: CNN dari awal vs *transfer learning*, signifikansi	G3
RM3: ketahanan pada ilustrasi *parallel* dan set baru	G2, G5
RM4: area perhatian model dan pengaruh watermark	G4

6. Dasar Metodologis Penelitian

Penelitian ini memakai CNN [11] dengan bobot *pretrained* ImageNet [12] berdasarkan temuan bahwa fitur visual dapat dipindahkan antar-tugas [13]. Arsitektur yang dibandingkan adalah ResNet-50 [14], MobileNetV2 [15], dan EfficientNet-B0 [16], ditambah CNN sederhana yang dilatih dari awal sebagai pembanding. Pembagian data dirancang untuk mencegah kebocoran [18], metrik dipilih untuk data tidak seimbang [19], perbedaan antar-model diuji dengan uji McNemar [20], [21], dan keputusan model dianalisis dengan Grad-CAM [17]. Studi kartu [1]–[6] dan studi lokal [7]–[10] menjadi acuan pembanding.

7. Catatan untuk Pengembangan Menjadi Paper (UAS)

- Lakukan penelusuran sistematis (kata kunci: *trading card recognition*, *card game image classification*, *Magic the Gathering CNN*, *Pokémon card detection*) di

Scopus/IEEE Xplore untuk memperkuat klaim G1.

- Baca naskah penuh [1] untuk memastikan klaim ✗ pada matriks, khususnya apakah memakai *transfer learning* dan bagaimana data dibagi.
- Tambahkan studi lokal tentang klasifikasi warna objek dan penanganan data tidak seimbang sebagai pembanding metodologis.
- Jika memungkinkan, tambahkan data dari set tanpa overlay "SAMPLE" untuk memperkuat analisis G4.

Daftar Pustaka

[1] F. Zilio, M. Prates, and L. Lamb, "Neural networks models for analyzing Magic: The Gathering cards," *arXiv preprint* arXiv:1810.03744, 2018.

[2] Nyckel, "Yugioh card category — pretrained classifier." [Online]. Available: https://edge.nyckel.com/pretrained-classifiers/yugioh-card-category/ (accessed Oct. 2026).

[3] A. Rosebrock, "An interview with Anthony Lowhur — Recognizing 10,000 Yugioh cards with computer vision and deep learning," *PyImageSearch*, Mar. 3, 2021. [Online]. Available: https://pyimagesearch.com/2021/03/03/an-interview-with-anthony-lowhur-recognizing-10000-yugioh-cards-with-computer-vision-and-deep-learning/

[4] E. Pua, "Real-time Pokémon card detection from tournament footage," Stanford CS231n course project report, 2024. [Online]. Available: https://cs231n.stanford.edu/2024/papers/real-time-pokemon-card-detection-from-tournament-footage.pdf

[5] P. Wzorek and T. Kryjak, "Training dataset generation for bridge game registration," *arXiv preprint* arXiv:2109.11861, 2021.

[6] M. Čampelj, "Sistem za razpoznavo igralnih kart na osnovi globokega učenja [Deep learning-based playing card recognition system]," Diplomsko delo, Fakulteta za strojništvo, Univerza v Ljubljani, Ljubljana, 2022.

[7] H. Herlawati, A. A. Hendharsetiawan, W. Priatna, A. P. Dzulqiyana, and R. A. Rahmadanti, "Komparasi kinerja ResNet50 dan MobileNetV2 pada klasifikasi citra multi-domain," *J. Komtika (Komputasi dan Informatika)*, vol. 10, no. 1, pp. 46–61, 2026, doi: 10.31603/komtika.v10.i1.16926.

[8] A. Rayhan, R. Hidayat, and R. Afyenni, "Perbandingan akurasi EfficientNetV2 dan MobileNetV2 pada klasifikasi makanan tradisional Indonesia," *J. Cerita*, vol. 10, no. 2, pp. 124–127, 2024, doi: 10.33050/cerita.v10i2.3326.

[9] A. C. Hartono and A. R. Muslikh, "Penerapan transfer learning MobileNetV2 pada klasifikasi citra jenis buah-buahan," *J. Inf. Syst. Appl. Dev. (JISAD)*, vol. 3, no. 2, pp. 103–111, 2025, doi: 10.26905/jisad.v3i2.16187.

[10] W. Supriyanti and D. A. Anggoro, "Classification of Pandavas figure in shadow puppet images using convolutional neural networks," *Khazanah Informatika*, vol. 7, no. 1, 2021, doi: 10.23917/khif.v7i1.12484.

[11] Y. LeCun, Y. Bengio, and G. Hinton, "Deep learning," *Nature*, vol. 521, no. 7553, pp. 436–444, 2015, doi: 10.1038/nature14539.

[12] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, "ImageNet: A large-scale hierarchical image database," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2009, pp. 248–255, doi: 10.1109/CVPR.2009.5206848.

[13] J. Yosinski, J. Clune, Y. Bengio, and H. Lipson, "How transferable are features in deep neural networks?" in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 27, 2014, pp. 3320–3328.

[14] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2016, pp. 770–778, doi: 10.1109/CVPR.2016.90.

[15] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen, "MobileNetV2: Inverted residuals and linear bottlenecks," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2018, pp. 4510–4520, doi: 10.1109/CVPR.2018.00474.

[16] M. Tan and Q. V. Le, "EfficientNet: Rethinking model scaling for convolutional neural networks," in *Proc. 36th Int. Conf. Mach. Learn. (ICML)*, PMLR vol. 97, 2019, pp. 6105–6114.

[17] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, "Grad-CAM: Visual explanations from deep networks via gradient-based localization," in *Proc. IEEE Int. Conf. Comput. Vis. (ICCV)*, 2017, pp. 618–626, doi: 10.1109/ICCV.2017.74.

[18] S. Kapoor and A. Narayanan, "Leakage and the reproducibility crisis in machine-learning-based science," *Patterns*, vol. 4, no. 9, p. 100804, 2023, doi: 10.1016/j.patter.2023.100804.

[19] H. He and E. A. Garcia, "Learning from imbalanced data," *IEEE Trans. Knowl. Data Eng.*, vol. 21, no. 9, pp. 1263–1284, 2009, doi: 10.1109/TKDE.2008.239.

[20] Q. McNemar, "Note on the sampling error of the difference between correlated

proportions or percentages," *Psychometrika*, vol. 12, no. 2, pp. 153–157, 1947, doi: 10.1007/BF02295996.

[21] T. G. Dietterich, "Approximate statistical tests for comparing supervised classification learning algorithms," *Neural Comput.*, vol. 10, no. 7, pp. 1895–1923, 1998, doi: 10.1162/089976698300017197.