RENCANA EVALUATION METRIC

KLASIFIKASI TIPE DAN WARNA KARTU DIGIMON CARD GAME MENGGUNAKAN CONVOLUTIONAL NEURAL NETWORK

Oleh:

Muhammad Abdul Aziz

NPM 23081010229

PROGRAM STUDI INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS PEMBANGUNAN NASIONAL "VETERAN"
JAWA TIMUR

2026

DAFTAR ISI

1. Prinsip Evaluasi **1**

2. Notasi **1**

3. Metrik Klasifikasi per Tugas **1**

4. Metrik Gabungan dan Ketahanan **2**

5. Uji Signifikansi Statistik **2**

6. Analisis Interpretabilitas (Grad-CAM) **3**

7. Aturan Keputusan (Kriteria Keberhasilan) **3**

8. Evaluasi Tahap Lanjutan (UAS, opsional) **4**

9. Ancaman terhadap Validitas **4**

10. Hasil Pilot (Uji Kelayakan Pipeline) **4**

11. Alat Hitung **6**

Daftar Pustaka **6**

1. Prinsip Evaluasi

1. **Dua tugas dinilai terpisah.** Tipe (4 kelas) dan warna (7 kelas) masing-masing punya metrik sendiri, ditambah satu metrik gabungan (*exact match*).
2. **Kelas kecil harus ikut dihitung.** Data sangat tidak seimbang (Digimon 73,6% kartu, putih 5,2%), sehingga metrik utama adalah *macro F1* [19], bukan *accuracy* saja.
3. **Tanpa kebocoran.** Gambar reguler dan *parallel* dari nomor kartu yang sama tidak pernah terpisah ke data latih dan data uji [18]. Data validasi hanya dipakai untuk *early stopping*, tidak pernah untuk pelaporan.
4. **Perbandingan adil.** Semua model memakai data, pembagian, augmentasi, dan *seed* yang identik.
5. **Perbedaan harus diuji.** Selisih antar-model dinyatakan "lebih baik" hanya jika lolos uji McNemar [20], [21] setelah koreksi Holm.
6. **Hasil negatif tetap dilaporkan.** Model yang tidak lebih baik, atau penurunan besar di skenario S2/S3, adalah temuan yang sah.

2. Notasi

Simbol	Arti
C	Jumlah kelas (4 untuk tipe, 7 untuk warna)
N	Jumlah gambar uji
TP_c, FP_c, FN_c	*True positive*, *false positive*, *false negative* untuk kelas c
n_c	Jumlah gambar uji yang kelas sebenarnya c
$t_i, \hat{t}_i$	Tipe sebenarnya dan tipe tebakan gambar ke-i
$w_i, \hat{w}_i$	Warna sebenarnya dan warna tebakan gambar ke-i
b, c'	Jumlah gambar yang benar di model A tetapi salah di model B, dan sebaliknya

3. Metrik Klasifikasi per Tugas

Metrik	Rumus	Makna
Precision kelas c	$P_c = \dfrac{TP_c}{TP_c + FP_c}$	Dari tebakan kelas c, berapa yang benar
Recall kelas c	$R_c = \dfrac{TP_c}{TP_c + FN_c}$	Dari kartu kelas c, berapa yang tertebak
F1 kelas c	$F1_c = \dfrac{2P_cR_c}{P_c + R_c}$	Rata-rata harmonik *precision* dan *recall*

Metrik	Rumus	Makna
Macro F1 (utama)	$\frac{1}{C}\sum_{c=1}^{C} F1_c$	Setiap kelas berbobot sama
Accuracy (utama)	$\frac{1}{N}\sum_{c} TP_c$	Proporsi tebakan benar
Balanced accuracy	$\frac{1}{C}\sum_{c=1}^{C} R_c$	Rata-rata *recall* per kelas
Weighted F1	$\sum_{c=1}^{C} \frac{n_c}{N} F1_c$	F1 berbobot jumlah data per kelas
Confusion matrix	Tabel label sebenarnya × tebakan	Pola kesalahan antar-kelas

Mengapa *macro F1*: model yang selalu menebak "Digimon" sudah mendapat *accuracy* tipe sekitar 71% (per gambar), tetapi *macro F1*-nya hanya sekitar 0,21.

4. Metrik Gabungan dan Ketahanan

Metrik	Rumus	Makna
Exact match	$\frac{1}{N}\sum_{i=1}^{N} \mathbb{1}[\hat{t}_i = t_i \wedge \hat{w}_i = w_i]$	Kartu terpilah benar hanya jika tipe **dan** warnanya benar
Penurunan pada ilustrasi *parallel*	$\Delta_{S2} = \overline{F1}_{S1} - \overline{F1}_{S2}$	Positif = performa turun pada ilustrasi baru
Penurunan pada set baru	$\Delta_{S3} = \overline{F1}_{S1} - \overline{F1}_{S3}$	Positif = performa turun pada set yang tidak dilatih
Selisih overlay	$\Delta_{WM} = F1_{\text{tanpa overlay}} - F1_{\text{dengan overlay}}$	Indikasi pengaruh watermark (eksploratif)
Waktu inferensi	ms per gambar (CPU dan GPU)	Kelayakan dipakai pada sistem pemilahan

5. Uji Signifikansi Statistik

Uji McNemar membandingkan dua model pada gambar uji yang sama (berpasangan), memakai prediksi gabungan seluruh *fold* sehingga setiap gambar diprediksi tepat satu kali [20], [21]:

$$\chi^2 = \frac{(|b - c'| - 1)^2}{b + c'}$$

Jika $b + c' < 25$, dipakai versi *exact* (binomial). Taraf signifikansi $\alpha = 0{,}05$. Karena

ada 6 pasangan model untuk setiap tugas, nilai-*p* dikoreksi dengan **metode Holm** untuk mengendalikan kesalahan tipe I akibat banyak perbandingan.

Hipotesis	Uji	Data
H1: *transfer learning* > CNN dari awal	McNemar + Holm	Prediksi gabungan S1
H2: perbedaan antar-arsitektur *transfer learning*	McNemar + Holm	Prediksi gabungan S1
H3: S2 < S1	Selisih *macro F1* + IK 95% (*bootstrap* 1.000 kali, *resampling* per nomor kartu)	S1 vs S2
H4: dengan overlay ≠ tanpa overlay	Selisih *macro F1* + IK 95% (*bootstrap*)	S1 per kelompok overlay

Setiap metrik juga dilaporkan sebagai **rata-rata ± simpangan baku** dari 5 putaran.

6. Analisis Interpretabilitas (Grad-CAM)

Grad-CAM [17] diterapkan pada lapisan konvolusi terakhir model terbaik, untuk sampel prediksi benar dan salah dari setiap kelas.

Kepala	Area yang diharapkan	Tanda jalan pintas
Warna	Bar nama kartu, terutama bagian kiri	Ilustrasi, tulisan “SAMPLE”, watermark toko
Tipe	Tata letak: kotak Lv., angka DP, kotak *security*, tulisan tipe	Ilustrasi atau watermark

7. Aturan Keputusan (Kriteria Keberhasilan)

Pertanyaan	Kriteria
Apakah model “berhasil” mengklasifikasikan?	*Macro F1* S1 jauh di atas *baseline* tebak-kelas-terbanyak (≈ 0,21 untuk tipe) dan *recall* setiap kelas > 0
Apakah *transfer learning* lebih baik?	H_0 hipotesis 1 ditolak (McNemar, *p* Holm < 0,05)
Apakah model tahan terhadap ilustrasi *parallel*?	IK 95% dari Δ_{S2} mencakup 0 atau Δ_{S2} kecil dibanding variasi antar-*fold*
Apakah model belajar dari desain kartu?	Grad-CAM menyala di bar nama dan tata letak pada sebagian besar sampel

Pertanyaan	Kriteria
Model mana yang direkomendasikan?	*Macro F1* tertinggi; bila tidak berbeda signifikan, pilih yang paling ringan (waktu inferensi terendah)

8. Evaluasi Tahap Lanjutan (UAS, opsional)

Evaluasi	Tujuan
Foto kamera kartu fisik (±100–200 foto)	Mengukur penurunan performa dari gambar katalog ke foto nyata
Set tambahan tanpa overlay "SAMPLE"	Memisahkan pengaruh watermark dari pengaruh set
Verifikasi label kedua oleh orang lain	Mengukur kesepakatan antar-pelabel

9. Ancaman terhadap Validitas

Ancaman	Penanganan
Kebocoran antar-varian	Pembagian per nomor kartu; pemeriksaan otomatis di setiap putaran
Label salah	Verifikasi ulang; jumlah koreksi dilaporkan
Watermark tercampur dengan set	Grad-CAM sebagai bukti pendukung; dinyatakan sebagai keterbatasan
Kelas sangat kecil (Digi-Egg putih hanya 1 kartu)	*Macro F1*, bobot kelas, stratifikasi gabungan; tidak menarik kesimpulan per kelas dari 1–2 sampel
Variasi hasil akibat *seed*	Rata-rata 5 putaran; *seed* dicatat
Penyetelan berlebihan pada data uji	*Hyperparameter* ditetapkan sebelum eksperimen; data uji tidak dipakai untuk memilih model
Gambar katalog ≠ foto nyata	Dinyatakan sebagai batasan; evaluasi foto kamera di tahap lanjutan

10. Hasil Pilot (Uji Kelayakan Pipeline)

M1 (CNN dari awal) pada skenario S1 *fold* 0: 474 gambar latih, 83 gambar validasi, 140 gambar uji. Pelatihan berjalan 25 *epoch* (bobot terbaik di *epoch* 17) di CPU 2 inti tanpa GPU, total 18,6 menit. Konfigurasi sama dengan rencana, kecuali batas *epoch* diturunkan

dari 60 menjadi 30 (sabar 8) karena keterbatasan waktu CPU. Model *transfer learning* (M2–M4) belum dijalankan karena bobot *pretrained* belum dapat diunduh di lingkungan penyusun; ketiganya dijalankan di Google Colab pada tahap berikutnya.

Metrik (data uji *fold* 0, 140 gambar)	M1 CNN dari awal	*Baseline* tebak kelas terbanyak
Accuracy tipe	0,764	0,721
***Macro F1* tipe**	**0,666**	0,210
Balanced accuracy tipe	0,740	0,250
Accuracy warna	0,743	0,200
***Macro F1* warna**	**0,712**	0,048
Balanced accuracy warna	0,740	0,143
Exact match (tipe dan warna benar)	0,529	—

Baseline tebak kelas terbanyak selalu menebak "Digimon" untuk tipe dan "merah" untuk warna (kelas terbanyak di data latih).

F1 per kelas — tipe:

Kelas	Precision	Recall	F1	Jumlah uji
Digimon	0,910	0,802	0,853	101
Tamer	0,625	0,500	0,556	20
Option	0,833	0,909	0,870	11
Digi-Egg	0,261	0,750	0,387	8

F1 per kelas — warna:

Kelas	Precision	Recall	F1	Jumlah uji
merah	0,950	0,679	0,792	28
biru	0,950	0,760	0,844	25
kuning	0,700	1,000	0,824	21
hijau	1,000	0,913	0,955	23
hitam	0,424	0,737	0,538	19
ungu	0,800	0,235	0,364	17
putih	0,545	0,857	0,667	7

Interpretasi jujur:

1. *Pipeline* berjalan dari awal sampai akhir: pembagian data per nomor kartu (tanpa kebocoran), augmentasi tanpa *flip* dan tanpa perubahan *hue*, pelatihan dua *head*, prediksi, dan perhitungan metrik.

2. Bahkan model paling sederhana yang dilatih dari awal dengan data sekecil ini sudah jauh di atas *baseline* tebak-kelas-terbanyak (*macro F1* tipe 0,666 vs 0,210; warna 0,712 vs 0,048). Artinya informasi tipe dan warna memang dapat dipelajari dari gambar.
3. Kelas tersulit pada pilot ini adalah tipe **Digi-Egg** (F1 0,387) dan warna **ungu** (F1 0,364). *Confusion matrix* menunjukkan pola yang jelas: 10 dari 17 kartu ungu ditebak hitam (keduanya gelap), dan 13 dari 101 kartu Digimon ditebak Digi-Egg (tata letak keduanya mirip, sama-sama memiliki kotak Lv.). Pola ini menjadi fokus analisis Grad-CAM dan perbandingan dengan model *transfer learning*.
4. *Exact match* gambar reguler 0,610 vs gambar *parallel* 0,325 pada *fold* ini. Angka ini belum setara skenario S2, karena pada S1 model juga melihat gambar *parallel* kartu lain saat latihan.
5. *Macro F1* gambar tanpa overlay "SAMPLE" (tipe 0,619, warna 0,624; 93 gambar) vs dengan overlay (tipe 0,782, warna 0,703; 47 gambar). Perbandingan ini masih tercampur dengan perbedaan set, sehingga belum dapat disimpulkan.
6. Ini **satu putaran** dengan **satu model**, sehingga belum ada kesimpulan tentang hipotesis. Hasil pilot hanya membuktikan kelayakan *pipeline* dan memberi titik acuan bagi M2–M4.

Berkas pendukung: `pilot_results.csv` (ringkasan), `pilot_per_kelas.csv` (metrik per kelas), `pilot_predictions_test.csv` (prediksi per gambar), `pilot_training_log.csv` (kurva pelatihan per *epoch*).

11. Alat Hitung

`scikit-learn` [25] (`f1_score`, `accuracy_score`, `balanced_accuracy_score`, `confusion_matrix`, `StratifiedGroupKFold`), `statsmodels` (`mcnemar`, `multipletests` untuk koreksi Holm), `pytorch-grad-cam` untuk Grad-CAM, dan `06-Kode/digimon_pipeline.py` (mode `ringkas`) untuk tabel hasil.

Daftar Pustaka

[17] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, "Grad-CAM: Visual explanations from deep networks via gradient-based localization," in *Proc. IEEE Int. Conf. Comput. Vis. (ICCV)*, 2017, pp. 618–626, doi: 10.1109/ICCV.2017.74.

[18] S. Kapoor and A. Narayanan, "Leakage and the reproducibility crisis in machine-learning-based science," *Patterns*, vol. 4, no. 9, p. 100804, 2023, doi: 10.1016/j.patter.2023.100804.

[19] H. He and E. A. Garcia, “Learning from imbalanced data,” *IEEE Trans. Knowl. Data Eng.*, vol. 21, no. 9, pp. 1263–1284, 2009, doi: 10.1109/TKDE.2008.239.

[20] Q. McNemar, “Note on the sampling error of the difference between correlated proportions or percentages,” *Psychometrika*, vol. 12, no. 2, pp. 153–157, 1947, doi: 10.1007/BF02295996.

[21] T. G. Dietterich, “Approximate statistical tests for comparing supervised classification learning algorithms,” *Neural Comput.*, vol. 10, no. 7, pp. 1895–1923, 1998, doi: 10.1162/089976698300017197.

[25] F. Pedregosa *et al.*, “Scikit-learn: Machine learning in Python,” *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.